

Deteksi Kesehatan Pohon Kelapa Sawit Menggunakan Deep Learning pada Citra Udara

Jeremy Mattathias Mboe¹, Seifeldein Akbar², Kayla Riza Putri Irjayanto³, Dini Adni Navastara⁴

¹Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember, Surabaya, 60111, email: 5054241012@student.its.ac.id

²Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember, Surabaya, 60111, email: 5054241032@student.its.ac.id

³Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember, Surabaya, 60111, email: 5054241028@student.its.ac.id

⁴Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember, Surabaya, 60111, email: dini_navastara@its.ac.id

Corresponding Author: Jeremy Mattathias Mboe

INTISARI — Pemantauan kondisi kesehatan pohon kelapa sawit secara manual memiliki keterbatasan dari segi skala, waktu, dan akurasi pada area perkebunan yang sangat luas. Hal ini dikarenakan proses yang memerlukan tenaga dan waktu yang besar serta berpotensi menimbulkan subjektivitas penilaian akibat perbedaan kemampuan pengamat. Untuk mengatasi kendala tersebut, penelitian ini mengusulkan sistem berbasis *Deep Learning* yang menggabungkan YOLOv8 untuk deteksi objek pohon kelapa sawit dan ResNet18 untuk klasifikasi kondisi kesehatan pohon. Data citra udara yang diperoleh dari *unmanned aerial vehicle* (UAV) diolah menjadi peta *Normalized Difference Vegetation Index* (NDVI) yang berfungsi mengekstraksi dan memperjelas tingkat kehijauan vegetasi sekaligus mengidentifikasi perbedaan kondisi tanaman, sehingga menjadi indikator penting dalam membedakan pohon yang sehat dengan pohon yang kurang sehat. Pada tahap pertama, YOLOv8 digunakan untuk mendeteksi posisi pohon secara otomatis dari citra udara, kemudian ResNet18 mengklasifikasikan setiap pohon ke dalam dua kategori utama, yaitu sehat dan kurang sehat berdasarkan fitur citra dan informasi NDVI. Hasil eksperimen menunjukkan bahwa sistem ini mampu melakukan deteksi dan klasifikasi dengan akurasi tinggi, di mana model YOLOv8s mencapai *precision* sebesar 96,7% dan model ResNet18 menghasilkan akurasi klasifikasi sebesar 92,41%. Dengan capaian tersebut, proses pemantauan perkebunan sawit dapat dilakukan secara lebih cepat, objektif, dan efisien. Temuan ini menegaskan potensi besar pemanfaatan teknologi *Computer Vision* dan citra udara dalam mengotomatisasi pengelolaan perkebunan, khususnya untuk meningkatkan produktivitas dan efektivitas pengambilan keputusan terkait perawatan serta pencegahan penyakit tanaman.

KATA KUNCI — Deteksi, Kesehatan Pohon Kelapa Sawit, Citra Udara, NDVI, YOLO, ResNet, UAV

I. PENDAHULUAN

A. LATAR BELAKANG DAN PERMASALAHAN

Kelapa sawit merupakan pilar utama dalam sektor ekonomi agrikultur Indonesia. Berdasarkan publikasi terbaru dari Badan Pusat Statistik (BPS) [1], total luas areal perkebunan kelapa sawit di Indonesia telah mencapai 15,34 juta hektar. Jika diasumsikan rata-rata kepadatan populasi pohon sawit adalah sekitar 143 pohon per hektar, maka diperkirakan terdapat lebih dari 2,1 miliar pohon sawit di seluruh Indonesia. Skala yang sangat besar ini menuntut adanya sistem monitoring yang tidak hanya canggih, tetapi juga efisien untuk menjaga produktivitas dan mendeteksi potensi masalah seperti penyakit atau kekurangan nutrisi secara dini [2].

Pemanfaatan teknologi drone [3] untuk akuisisi citra udara telah menjadi langkah maju dalam pengelolaan perkebunan, namun data visual yang dihasilkan masih membutuhkan interpretasi lebih lanjut agar dapat memberikan nilai strategis. Permasalahan utama terletak pada inefisiensi dan subjektivitas proses analisis citra secara manual. Pemeriksaan visual terhadap ribuan pohon melalui layar komputer sangat memakan waktu dan rentan terhadap kesalahan akibat kelelahan dan inkonsistensi persepsi warna, terutama dalam membedakan kondisi kesehatan pohon berdasarkan citra RGB. Kondisi ini menjadikan metode manual tidak dapat diandalkan untuk skala industri yang luas.

B. TUJUAN DAN KONTRIBUSI PENELITIAN

Untuk menjawab permasalahan tersebut, penelitian ini memiliki tujuan untuk mengembangkan sistem deteksi dan klasifikasi kesehatan pohon sawit otomatis untuk data citra RGB dari drone, yang dapat menggantikan analisis visual manual secara lebih cepat dan objektif. Sistem ini memiliki dua fungsi utama: mengidentifikasi serta menghitung jumlah pohon sawit dalam suatu area, dan mengklasifikasikan kesehatan masing-

masing pohon ke dalam kategori sehat atau kurang sehat. Kontribusi utama penelitian ini adalah membangun sistem dua *pipeline* yang terintegrasi, yaitu *pipeline object detection* menggunakan YOLOv8s dan *pipeline image classification* menggunakan ResNet18 yang dioptimalkan melalui pendekatan NDVI [4]. Selain itu, penelitian ini juga menyusun *custom dataset* dari citra drone perkebunan sawit di Indonesia, untuk memastikan model yang dihasilkan memiliki akurasi dan relevansi tinggi terhadap kondisi lapangan lokal [5]. Sistem yang dikembangkan ini diharapkan dapat menjadi solusi pemantauan perkebunan sawit yang cepat, hemat biaya, dan dapat diskalakan [6], serta membuka peluang menuju pengambilan keputusan berbasis data yang lebih akurat dan efisien.

II. KAJIAN TEORI

Pengembangan sistem deteksi pohon sawit dan analisis kesehatannya secara otomatis memerlukan pemahaman mendalam terhadap konsep-konsep dasar dari solusi yang diusulkan. Kajian ini mencakup teori-teori utama seperti *Object Detection* dan *Image Classification* dengan *Deep Learning*, beserta NDVI untuk pengolahan indeks vegetasi.

A. CITRA UDARA DAN NORMALIZED DIFFERENCE VEGETATION INDEX (NDVI)

Teknologi *Remote Sensing* dapat dimanfaatkan untuk pemantauan kondisi perkebunan secara lebih efisien dan akurat melalui penggunaan citra udara. Dalam konteks perkebunan kelapa sawit, citra udara diambil menggunakan drone UAV. Salah satu metode yang umum digunakan untuk mengevaluasi kesehatan tanaman berdasarkan citra udara adalah NDVI (*Normalized Difference Vegetation Index*). NDVI merupakan indeks vegetasi yang dihitung dengan rumus [7] berikut:

$$NDVI = \frac{NIR-R}{NIR+R} \quad (1)$$

di mana NIR adalah pantulan spektral pada pita inframerah dekat (*Near-Infrared*), dan R adalah pantulan pada pita merah. Tanaman sehat memiliki nilai NDVI yang tinggi karena memantulkan lebih banyak cahaya NIR dan menyerap lebih banyak cahaya merah.

Namun, rumus ini mengharuskan adanya kanal NIR yang hanya dapat diperoleh melalui kamera multispektral. Dalam proyek ini, kamera yang digunakan adalah kamera RGB standar, sehingga tidak tersedia kanal NIR secara langsung. Untuk mengatasi hal ini, pendekatan yang digunakan adalah membangkitkan kanal NIR berdasarkan transformasi dari kanal RGB yang tersedia.

Dengan demikian, perhitungan NDVI tetap dapat dilakukan menggunakan rumus standar, tetapi dengan NIR estimasi, bukan hasil tangkapan sensor inframerah yang sesungguhnya. Setelah kanal R dan NIR tersedia, perhitungan NDVI dilakukan dengan rumus tersebut. Untuk menghindari pembagian dengan nol, nilai NIR+R yang bernilai nol digantikan dengan nilai kecil seperti 0,01. Nilai NDVI yang dihasilkan kemudian diklasifikasikan berdasarkan ambang batas [8] sebagai berikut:

- $NDVI < 0.11$ → Non-vegetasi (warna merah)
- $0.11 \leq NDVI < 0.22$ → Vegetasi tidak sehat (kuning)
- $0.22 \leq NDVI < 0.42$ → Vegetasi normal (oranye)
- $NDVI \geq 0.42$ → Vegetasi sehat (hijau)

Kesehatan sebuah pohon sawit dikategorikan ke kelas kurang sehat dan sehat. Bukti adanya korelasi positif antara kehijauan sebuah pohon sawit dengan nilai NDVI [9] dan semakin hijau sebuah pohon dari citra udara maka semakin sehat juga pula kondisinya, sehingga proses pelabelan dataset menjadi lebih mudah. Namun, transformasi citra udara RGB ke NDVI yang dijelaskan pada Bab IV Bagian A terbukti membantu model klasifikasi dalam mengekstrak fitur yang penting dari warna hijau sebuah pohon.

Kelas hanya dikategorikan menjadi kurang sehat dan sehat karena masih diperlukan data-data selain warna yang bisa didapat dari citra udara contohnya kondisi tanah, akar, dan juga gejala penyakit yang memerlukan data langsung (tidak hanya dari udara) untuk mengklasifikasikan pohon sawit yang sakit, dan *under trees*. Hasil klasifikasi NDVI ini divisualisasikan dalam bentuk peta warna (*mask*) dan kemudian digabungkan secara semi-transparan (*blending*) dengan citra RGB asli untuk mempermudah interpretasi visual. Proses ini menghasilkan NDVI yang menyerupai tampilan NDVI dari kamera multispektral, dan digunakan sebagai input untuk model klasifikasi berikutnya (ResNet18) dalam *pipeline* deteksi kesehatan pohon sawit.

B. OBJECT DETECTION DENGAN YOLOV8

YOLO (*You Only Look Once*) merupakan model deteksi objek yang dapat melakukan prediksi bounding box dan klasifikasi objek secara langsung dari gambar. YOLOv8 merupakan salah satu versi dari YOLO [10] yang mengusung pendekatan *anchor-free*, di mana tidak lagi mengandalkan *anchor boxes* sebagai acuan awal dalam mendeteksi objek. Arsitektur YOLOv8 terbagi menjadi tiga bagian utama [11]: *Backbone*, *Neck*, dan *Head*. *Backbone* bertugas mengekstraksi fitur dasar dari sebuah gambar, dengan komponen utama Conv (konvolusi standar), C2f (modul fusi fitur), dan SPPF (*pooling* untuk menangkap konteks objek). *Backbone* menghasilkan tiga *output* dengan kedalaman berbeda (P3, P4, P5) yang akan diteruskan ke bagian lain.

Bagian *Neck* berfungsi menggabungkan fitur dari berbagai

skala menjadi proses *upsampling*, *concatenation* (penggabungan), dan C2f. Proses ini memungkinkan YOLOv8 mendeteksi objek dengan berbagai ukuran secara efisien. Terakhir, Head menggunakan *layer* konvolusi dan *Detect Blocks* untuk menghasilkan prediksi akhir berupa : Bounding Box Regression (koordinat objek), *Class Probability* (kategori objek), dan *Objectness Score* (keyakinan model terhadap keberadaan objek). YOLOv8 menggunakan kombinasi *loss function*, termasuk *Box Loss*, *Class Entropy Loss*, dan *Objectness Loss* untuk performa yang optimal.

C. IMAGE CLASSIFICATION DENGAN RESNET18

ResNet18 merupakan salah satu arsitektur CNN yang menggunakan *residual connections* atau *skip connections* [12]. Koneksi ini memungkinkan informasi dan gradien mengalir lebih efektif dengan membantu mengatasi masalah *vanishing gradient* pada jaringan yang sangat dalam. Arsitektur ResNet18 memiliki 18 *layer* yang dapat dilatih. Inti dari ResNet adalah *residual block*, yang melatih lapisan mempelajari fungsi residual $F(x) = H(x) - x$.

Output yang diinginkan menjadi $H(x) = F(x) + x$. Koneksi x ini disebut *skip connections*, yang menambahkan input dari blok langsung ke *output*. Arsitektur ResNet18 dimulai dengan lapisan konvolusi dan *max pooling* untuk mengurangi dimensi spasial, lalu dilanjutkan dengan empat *layer* utama (*Layer 1-4*). Setiap *layer* terdiri dari dua *basic blocks* dengan filter yang semakin banyak dan *downsampling* spasial untuk menangani objek pada skala yang berbeda.

Setelah semua lapisan konvolusi, arsitektur diakhiri dengan *Global Average Pooling* (GAP) untuk mengambil rata-rata feature map, mengurangi jumlah parameter dan risiko overfitting. *Output* dari GAP kemudian diteruskan ke *Fully Connected Layer* (FC) untuk klasifikasi, yang biasanya menggunakan fungsi *Softmax* untuk menghasilkan probabilitas kelas.

III. SOLUSI USULAN

A. DATASET

Dataset yang digunakan didapatkan dari PT. Global Pro Indonesia yang bersifat *private*. Dataset yang digunakan untuk alur kerja sistem merupakan foto mentah Gambar 1 suatu bagian dari kebun sawit yang berukuran 2225 x 2225 *pixel*. Dataset yang mentah nantinya akan digunakan untuk *training* dan *testing* untuk model YOLOv8. Dataset mentah nantinya akan dilakukan *preprocessing* untuk *training* ResNet18, yaitu dengan melakukan *masking* dengan NDVI kemudian untuk setiap *bounding box* pohon sawit akan dipisah menjadi satu file foto sendiri yang nantinya digunakan untuk *training* ResNet18.



Gambar 1. Contoh Data Foto Mentah Kebun Sawit (Dataset YOLOv8)

1) DATASET TRAINING YOLOV8

Dataset foto kebun sawit mentah dianotasi di *platform* Roboflow. Objek yang dianotasi adalah semua pohon sawit yang ada di kebun. YOLOv8 secara otomatis melakukan proses *resize*

pada gambar agar sesuai dengan arsitektur model. Ukuran *default* yang digunakan dalam *training* ini adalah 640x640 *pixel*. Total dataset yang digunakan terdiri atas 90 citra resolusi tinggi, dengan jumlah total anotasi pohon sawit sebanyak 11,044 foto. Dataset ini kemudian dibagi menjadi tiga subset:

- *Training Set* (85%) : 76 gambar untuk proses pelatihan.
- *Validation Set* (11%) : 10 gambar untuk evaluasi kinerja model dalam pelatihan.
- *Testing Set* (4%) : 4 gambar yang tidak pernah dilihat model untuk pengujian.

2) DATASET TRAINING RESNET18

Dataset untuk melatih model klasifikasi ResNet18 dibangun dari hasil deteksi model YOLOv8. Setiap *bounding box* yang berhasil mendeteksi pohon sawit diekstrak (*crop*) menjadi sebuah gambar individual. Selanjutnya, setiap gambar pohon ini diproses melalui transformasi NDVI untuk menonjolkan fitur-fitur yang berkaitan dengan kesehatan vegetasi. Setelah transformasi, setiap gambar di Gambar 2 yang diberi label secara manual ke dalam dua kategori: sehat atau kurang sehat.

Total dataset untuk klasifikasi ini terdiri dari 525 gambar pohon individual. Dataset ini kemudian dibagi menjadi tiga subset:

- *Training Set* (70%) : 367 gambar, terdiri dari 257 gambar kelas sehat dan 110 gambar kelas kurang sehat.
- *Validation Set* (15%) : 79 gambar, terdiri dari 56 gambar kelas sehat dan 23 gambar kelas kurang sehat.
- *Testing Set* (15%) : 79 gambar, terdiri dari 56 gambar kelas sehat dan 23 gambar kelas kurang sehat.



(a)



(b)

Gambar 2. Contoh gambar, (a) kelas kurang sehat, (b) kelas sehat

B. TRAINING MODEL DETEKSI POHON SAWIT DENGAN YOLOV8

Training model YOLOv8 dilakukan menggunakan *library* Ultralytics YOLOv8, yang merupakan *framework object detection* berbasis Python dan PyTorch. Model yang digunakan dalam proyek ini adalah YOLOv8s yang merupakan versi ringan dari keluarga YOLOv8. Pada proses *training* gambar mentah akan dilakukan *preprocessing* secara otomatis dengan diubah ukurannya menjadi 640 x 640 *pixel* menggunakan teknik *letterboxing*, yaitu mempertahankan rasio aspek gambar asli dengan menambahkan *padding* jika diperlukan. Konfigurasi untuk training YOLOv8 adalah sebagai berikut :

- Model : YOLOv8s

- Jumlah *Epoch* : 30
- *Batch Size* : 16
- *Optimizer* : AdamW
- *Loss Function* : Gabungan dari *box regression loss*, *Distribution Focal Loss*, dan *classification loss*.
- Metode Validasi : *mean Average Precision* (mAP), *precision*, dan *recall*.

C. TRAINING MODEL KLASIFIKASI KESEHATAN POHON KELAPA SAWIT DENGAN RESNET18

Proses *training* untuk model klasifikasi kesehatan pohon dilakukan menggunakan *framework* PyTorch, dengan memanfaatkan implementasi model ResNet18 yang sudah tersedia dalam *library* torchvision. Model ini menggunakan bobot *pretrained* dari ImageNet, yang memungkinkan proses *transfer learning* untuk mempercepat konvergensi dan meningkatkan performa pada dataset yang lebih spesifik. Lapisan klasifikasi akhir (*fully connected layer*) dari ResNet18 telah dimodifikasi agar sesuai dengan jumlah kelas pada dataset ini, yaitu 2 kelas (sehat dan kurang sehat).

- Model : ResNet 18
- Jumlah *Epoch* : 10
- *Batch Size* : 32
- *Optimizer* : Adam
- *Learning rate* : 0.001
- *Loss Function* : *CrossEntropyLoss*
- Metode Validasi : *Accuracy*

D. ALUR KERJA SISTEM DETEKSI DAN KLASIFIKASI KESEHATAN POHON SAWIT

Alur Kerja sistem ini dirancang sebagai sebuah pipeline pemrosesan otomatis yang terdiri dari beberapa langkah sekuensial seperti pada *flowchart* di Gambar 3 . Sistem menerima input berupa citra drone RGB dari sebuah area perkebunan kelapa sawit dan menghasilkan *output* berupa peta visual kesehatan pohon beserta ringkasan data.



Gambar 3. Flowchart Sistem Deteksi dan Klasifikasi Kesehatan Pohon Sawit

- 1) Input Citra Udara RGB: Citra udara kebun sawit dalam format RGB diunggah
- 2) Deteksi Pohon Sawit dengan model YOLOv8 yang telah dilatih : YOLOv8 mendeteksi dan menghasilkan *bounding box* untuk setiap pohon sawit.
- 3) Konversi Citra RGB menjadi NDVI : Citra RGB dikonversi menjadi citra rekayasa NDVI untuk mengekstrak fitur penting.
- 4) Proyeksi dan Ekstraksi *Bounding Box* : *Bounding box* diproyeksikan ke citra rekayasa NDVI, lalu diekstrak menjadi citra per pohon.
- 5) Klasifikasi Kesehatan dengan ResNet18 : Setiap citra pohon diklasifikasi oleh model ResNet18 ke kelas sehat atau kurang sehat.
- 6) Proyeksi Hasil Klasifikasi : Label klasifikasi diproyeksikan kembali ke citra asli dengan penanda warna *bounding box*.

7) *Output Akhir* : Sistem menampilkan citra RGB dengan penanda kelas sehat atau kurang sehat dan jumlah pohon berdasarkan kategori kesehatan.


IV. HASIL PENGUJIAN DAN PEMBAHASAN

Semua kode program pengembangan dibuat dalam bahasa Python dengan menggunakan *library* OpenCV untuk memproses gambar. *Library* Ultralytics dan Roboflow digunakan untuk membuat model deteksi objek dari *pre-trained* model YOLOv8. Pytorch digunakan untuk membuat model klasifikasi gambar dari *pre-trained* model ResNet18. Komputasi dilakukan di Google Colab, dengan spesifikasi:

- *Hardware Accelerator* : T4 GPU
- *System RAM* : 12 GB
- *Operating System* : Windows 10

A. KLASIFIKASI KESEHATAN POHON SAWIT DENGAN NDVI DAN TANPA NDVI

NDVI sebagai fitur ekstraksi merupakan kunci dalam sistem ini untuk bisa mengklasifikasikan sehat atau kurang sehatnya pohon sawit dalam citra udara. Pada tahapan awal, diteliti perbedaan keberhasilan model klasifikasi ResNet18 dalam melakukan klasifikasi dengan NDVI dan tanpa NDVI dengan menggunakan sampel sebanyak 234 gambar *bounding box* pohon sawit dengan 127 sawit kurang sehat dan 107 sawit sehat, seperti yang ditunjukkan pada Gambar 4 pada penjelasan dataset. Dataset dipisah dengan jumlah 164 *train* , 27 *valid*, dan 23 *test*.



Gambar 4. Contoh gambar, (a) Tanpa NDVI sehat, (b) Tanpa NDVI kurang sehat, (c) NDVI sehat, (d) NDVI kurang sehat

Dari eksperimen ini dihasilkan *accuracy* pada *test set* sebesar 65,22% pada model klasifikasi ResNet18 tanpa NDVI dan 86,96%. Hasil *confusion matrix test set* dari ResNet18 yang dilatih tanpa NDVI adalah *true* kurang sehat sebanyak 11, *false* kurang sehat sebanyak 0, *true* sehat sebanyak 4 dan *false* sehat sebanyak 8. Sementara itu, untuk model ResNet18 yang dilatih dengan NDVI memiliki *confusion matrix* dengan *true* kurang sehat 10, *false* kurang sehat 1, *true* sehat 10 dan *false* sehat sebanyak 2.

B. PERBANDINGAN HASIL DETEKSI MODEL YOLOV8S DENGAN YOLOV10S

Evaluasi model deteksi dilakukan terhadap dua model, YOLOv8s dan YOLOv10s, menggunakan 10 gambar dari *validation set* yang telah dianotasi secara manual. TABEL I menyajikan perbandingan metrik evaluasi utama antara kedua model.

TABEL I.

PERBANDINGAN HASIL EVALUASI YOLOV8S DENGAN YOLOV10S

Model	Precision	Recall	mAP@0,5	mAP@0,5:0,95
YOLOv8s	96,7%	97,2%	99,1%	80,5%
YOLOv10s	95,5%	96,8%	98,6%	82,5%

YOLOv8s menunjukkan nilai *precision* dan mAP@0,5 yang lebih tinggi, mencerminkan akurasi deteksi yang sangat baik. Di sisi lain, YOLOv10s unggul dalam metrik mAP@0,5:0,95, yang menunjukkan kestabilan performa pada berbagai nilai ambang IoU.

Evaluasi lanjutan dilakukan pada 4 gambar dari *test set* untuk membandingkan kedekatan prediksi terhadap jumlah objek nyata, seperti ditunjukkan pada TABEL II.

TABEL II

PERBANDINGAN JUMLAH DETEKSI POHON SAWIT PADA *TEST SET*

Gambar	Jumlah Asli	Deteksi YOLOv8s	Deteksi YOLOv10s
1	130	130	108
2	147	146	124
3	152	152	135
4	116	125	115

Model YOLOv8s menghasilkan prediksi yang sangat dekat dengan jumlah pohon sawit sebenarnya, terutama pada gambar 1 hingga 3. Meskipun begitu, YOLOv10s tetap kompetitif dan menunjukkan kestabilan deteksi yang baik secara umum. Secara keseluruhan, pilihan model dapat disesuaikan berdasarkan kebutuhan antara akurasi tinggi (YOLOv8s) dan kestabilan performa (YOLOv10s).

C. PERBANDINGAN HASIL KLASIFIKASI RESNET18 UNTUK DUA PIPELINE DAN YOLOV8S UNTUK SATU PIPELINE

Pengujian model *image classification* ResNet18 yang dilakukan pada *test set* 79 gambar mendapatkan hasil akurasi 92,41%. Hasil dari *confusion matrix* sebagai berikut : *true* sehat sebanyak 56, *false* sehat sebanyak 0, *true* kurang sehat sebanyak 17, dan *false* kurang sehat sebanyak 6. Pengujian ini menghasilkan sebuah model dengan akurasi cukup tinggi, namun tetap diperlukan pengujian klasifikasi dengan YOLOv8s untuk satu *pipeline* secara langsung yang ditunjukkan pada TABEL III.

Eksperimen ini bertujuan untuk membandingkan performa model klasifikasi dengan dua *pipeline* (YOLOv8 untuk deteksi pohon sawit dan ResNet18 untuk klasifikasi kesehatan) dan satu *pipeline* (YOLOv8 untuk deteksi dan klasifikasi kesehatan pohon sawit). Dengan dilakukannya eksperimen ini, maka dapat dilakukan pengambilan keputusan untuk memisahkan model deteksi dan klasifikasi.


TABEL III

PERBANDINGAN EVALUASI MODEL KLASIFIKASI DUA PIPELINE DENGAN SATU PIPELINE PADA *TEST SET*

Model	Accuracy	Recall	Precision	F1 Score
ResNet18	92,41%	100,00%	90,32%	94,96%
YOLOv8s	78,50%	90,50%	61,00%	76,70%

Setelah mentransformasi *raw image* seperti Gambar 1 ke Gambar 5 yang sudah NDVI dan melakukan anotasi kondisi sehat atau kurang sehat, diketahui bahwa performa deteksi cukup baik dengan nilai Recall tinggi sebesar 0.905. Namun,

nilai *precision* yang sedang mengindikasikan keterbatasan dalam membedakan pohon sehat dan kurang sehat secara konsisten. Sebaliknya, pendekatan dua *pipeline* memberikan performa klasifikasi yang lebih tinggi dengan penggunaan NDVI yang memberikan informasi vegetasi yang jelas.



Gambar 5. Contoh gambar raw image yang sudah di-masking NDVI untuk pengujian deteksi dan klasifikasi satu pipeline (YOLOv8s)

Secara keseluruhan, pendekatan dua *pipeline* memberikan akurasi klasifikasi yang lebih tinggi namun dengan kompleksitas sistem arsitektur yang lebih besar. Dalam konteks penelitian ini, pendekatan dengan dua *pipeline* dinilai lebih sesuai untuk *monitoring* berskala besar yang dapat digunakan untuk membantu pemantauan kesehatan pohon sawit.

E. PEMBAHASAN

Evaluasi dilakukan secara terpisah pada masing-masing model karena dataset *training* dan *testing* untuk deteksi dengan YOLOv8 dan ResNet18 berasal dari skema anotasi yang berbeda. Oleh karena itu, akurasi *pipeline* secara *end-to-end* tidak dapat diukur secara langsung yang berarti metrik pengukuran untuk deteksi dan klasifikasi harus dipisah dengan hasil metrik pada TABEL IV. Beberapa metode dengan model lain sudah pernah dilakukan, seperti pada artikel jurnal [13] yang menggunakan Faster R-CNN sebagai model deteksi dengan ResNet50 dan VGG-16 sebagai model klasifikasi dengan hasil metrik evaluasi yang ditunjukkan di TABEL V.

TABEL IV
EVALUASI KINERJA MODEL TERHADAP DETEKSI DAN KLASIFIKASI POHON SAWIT DENGAN SOLUSI USULAN

Model dan Metrik	Nilai
Pohon Sawit (YOLOv8) <i>Precision</i>	96,80%
Pohon Sawit(YOLOv8) <i>Recall</i>	97,60%
Sehat (ResNet18) <i>Precision</i>	90,32%
Sehat(ResNet18) <i>Recall</i>	100,00%
Kurang Sehat (ResNet18) <i>Precision</i>	100,00%
Kurang Sehat (ResNet18) <i>Recall</i>	73,91%

TABEL V
EVALUASI KINERJA MODEL FASTER R-CNN DENGAN BACKBONE RESNET50 DAN VGG-16

Model dan Metrik	ResNet50	VGG-16
Pohon Sawit (Faster R-CNN) <i>Precision</i>	96,34%	95,15%
Pohon Sawit(Faster R-CNN) <i>Recall</i>	93,88%	90,51%
Sehat <i>Precision</i>	91,24%	98,13%
Sehat <i>Recall</i>	92,92%	80,92%
Kurang Sehat <i>Precision</i>	98,04%	63,11%
Kurang Sehat <i>Recall</i>	78,13%	97,01%

V. KESIMPULAN

Penelitian ini berhasil mengembangkan dan menerapkan *pipeline* dua tahap untuk deteksi dan analisis kesehatan pohon kelapa sawit secara otomatis menggunakan citra RGB standar.

Tahap pertama menggunakan model deteksi objek YOLOv8s untuk mengidentifikasi dan melokalisasi setiap pohon sawit dari citra udara. Setelah itu, setiap pohon yang terdeteksi diproses dengan transformasi NDVI guna mengekstraksi ciri-ciri vegetasi, dan kemudian diklasifikasikan ke dalam kategori sehat atau kurang sehat oleh model klasifikasi ResNet18. Model ResNet18 menunjukkan performa klasifikasi yang baik dengan akurasi sebesar 92,41% sementara model deteksi YOLOv8s juga menunjukkan performa tinggi dengan nilai *precision* sebesar 96,70% dan *recall* sebesar 97,20%. Untuk tahap selanjutnya, efektivitas sistem ini dapat ditingkatkan dengan menambah variasi data latih dan mengeksplorasi berbagai metode atau indeks vegetasi berbasis RGB (seperti VARI dan GLI) untuk memperoleh transformasi citra yang lebih optimal.

REFERENSI

[1] Solimah, U. Mawarsari dan D. Susilo, Statistik Kelapa Sawit Indonesia 2023, Jakarta: Badan Pusat Statistik Indonesia, 2024.

[2] M. H. Abdillah, M. Lukmana dan N. Zakiah, "Identifikasi Penyakit Dominan Kelapa Sawit Menggunakan Pendekatan Visual Pada Tanaman Belum Menghasilkan, Tanaman Menghasilkan, Serta Pengendaliannya Yang Bisa Dilakukan Di Perkebunan PT. XY," *Jurnal HPT (Hama Penyakit Tumbuhan)*, vol. 13, no. 1, pp. 1-17, 2025.

[3] R. Guebsi, S. Mami dan K. Chokmani, "Drones in Precision Agriculture: A Comprehensive Review of Applications, Technologies, and Challenges," *Drones*, vol. 8, no. 11, p. 686, 2024.

[4] N. H. A. Pangestu dan G. Banowati, "Pemetaan Kesehatan Kebun Kelapa Sawit Berdasarkan Nilai Normalized Difference Vegetation Index (NDVI) Menggunakan Citra Landsat-8 Di Kebun PT. Wanapotensi Guna," *Agriprima : Jurnal Penyuluhan Pertanian*, vol. 7, no. 1, pp. 40 - 49, 2023.

[5] A. Minarto, M. H. Ramadhan, A. Lie dan E. Irwansyah, "Oil palm tree counting and abnormality assessment using deep learning and index vegetation," *Procedia Computer Science*, vol. 245, pp. 768-777, 2024.

[6] M. S. dan M. Rusdi, "Penggunaan Drone Untuk Pemetaan Kebun Kelapa Sawit (Studi Kasus: Kebun Kelapa Sawit Rakyat Desa Blang Kuta, Kecamatan Peudawa Rayeuk)," *Jurnal Ilmiah Mahasiswa Pertanian*, vol. 9, no. 3, 2024.

[7] A. Essaadia, A. Abdellah, A. Ahmed, F. Abdelouahed dan E. Kamal, "The normalized difference vegetation index (NDVI) of the Zat valley, Marrakech: comparison and dynamics," *Heliyon*, p. 5, 2022.

[8] P. Rahaldi, H. H. Handayani dan A. Wibowo, "Analisa Kesehatan Tanaman Padi Berdasarkan Nilai Normalized Difference Vegetation Index (NdvI) Menggunakan Citra Aster (Studi Kasus : Kabupaten Indramayu - Jawa Barat)," *Jurnal Teknik ITS*, vol. 2, no. 1, p. 112, 2013.

[9] U. Samarawickrama, D. Piyaratne dan M. Ranagalage, "Relationship between NDVI with Tasseled cap Indices: A Remote Sensing based Analysis," *IJIRT*, vol. 3, no. 12, pp. 18 - 19, 2017.

[10] M. Yaseen, "What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector," pp. 3 - 8, 2024.

[11] G. Yao, S. Zhu, L. Zhang dan M. H. Qi, "HP-YOLOv8: High-Precision Small Object Detection Algorithm for Remote Sensing Images," *Sensors*, vol. 24, no. 15, pp. 5 - 15, 2024.

[12] X. Z. S. R. J. S. Kaiming He, "Deep Residual Learning for Image Recognition," dalam *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, 2016.

[13] A. W. K. K. C. A. R. S. Kanitta Yarak, "Oil Palm Tree Detection and Health Classification on High-Resolution Imagery Using Deep Learning," *Agriculture*, vol. 11, no. 2, pp. 7 - 14, 2021.